天气预报：数据采集+可视化+单变量线性回归模型

一、数据采集

1.审查网页元素

打开杭州市8月份的天气预报(http://www.tianqihoubao.com/lishi/hangzhou/month/202008.html)，审查元素。

发现信息包括：日期、天气状况、气温、风力状况，这四个信息都存在<tr>元素中，每个<tr>元素中有四个<td>元素， 分别存放这四项信息。所以在爬取8月份的数据时，只需要对着30个<tr>元素进行循环存储就可以了。

日期	天气状况	气温	风力风向
2020年08月01日	多云/多云	36℃ / 26℃	南风 3-4级 /南风 3-4级
2020年08月02日	多云/多云	37℃ / 26℃	南风 3-4级 /南风 3-4级
2020年08月03日	多云/多云	36℃ / 27℃	东南风 4-5级 /东南风 4-5级
2020年08月04日	中雨/小到中雨	32℃ / 26℃	南风 6-7级 /南风 6-7级
2020年08月05日	多云/阴	35℃ / 27℃	南风 4-5级 /南风 4-5级
2020年08月06日	阴/多云	35℃ / 28℃	西南风 4-5级 /西南风 4-5级
2020年08月07日	多云/小雨	36℃ / 28℃	西南风 3-4级 /西南风 3-4级

2.建立请求头

分析好页面后，就可以开始爬虫，在正式爬虫前，需要建立一些请求头(这个网站暂时没有发现反爬的措施，不加请求头也是可以的)。使用postman工具可以快速伪造出请求头的参数。伪造的请求头形如下：

```
headers = {
    'User-Agent':
    'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Ch
}
```

3.数据爬取+数据存储

需要模块

- request(建立对网页的请求)
- bs4(对网页的元素进行解析)
- pandas(对获得数据进行清洗存放)

具体过程

使用request获取网页的内容，用beautiful库将获取的内容进行解析成为课寻找元素的对象。在这个对象中寻找所有的<tr>元素，在周到的所有元素中获取text内容，并将这些文本使用split()方法切割成列表，然后再经过调试确定需要寻找的内容所在的位置，使用切片和字符串连接分别存入三个变量(日期，天气情况，气温)中，再将这三个变量打包成一个列表，每次循环将该列表存入20天的大列表中，最后在主函数中使用pandas库将列表中的数据存入表格中。将这些代码封装成函数即可。

代码

```
# -*- encoding: utf-8 -*-
# here put the import lib
import requests
from bs4 import BeautifulSoup
import pandas as pd

# 获取天气数据
def get_data():
    url = "http://www.tianqihoubao.com/lishi/hangzhou/month/202008.html"
    Weathers = []
    headers = {
        'User-Agent':
        'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML,
like Gecko) Chrome/86.0.4240.75 Safari/537.36',
    }
    # get方式请求网页 获取源码文本
    strpage = requests.request("GET", url, headers = headers).text
    # 将源码解析 缩小范围 用'lxml'加快解析速度
    Soup = BeautifulSoup(strpage, 'lxml')
    # 寻找所有tr表格元素
    All_tr = Soup.find_all('tr')
    # 在获取的tr元素中查找相对应的信息元素
    for x in All_tr[1:21]:
        # 拆分字符串，形成数组
        List = x.text.split()
        # 日期
        date = ''.join(List[0])
        # 天气情况
        weather = ''.join(List[1:3])
        # 气温
        T = ''.join(List[3:6])
        # 将三大信息加入到/list中
        Weathers.append([date, weather, T])
    return Weathers
```

二、数据可视化

需要模块

- matplotlib.pyplot (python图形库)
- numpy (将数据转换成矩阵)
- import pandas (对表格的处理)

数据清洗

获取的数据有些不需要放在图像中，所以需要对表格中的数据进行一定的处理，主要用到的是split()、replace()方法。其中有一个比较特殊的情况是得到的日期为字符，不是数字，所以需要将字符转换成数字，这样才能在坐标轴中正确的排序。

```
data['最高气温'] = data['气温'].str.split('/', expand=True)[0]
data['最高气温'] = data['最高气温'].map(lambda x: int(x.replace('℃', '')))
data['最低气温'] = data['气温'].str.split('/', expand=True)[1]
data['最低气温'] = data['最低气温'].map(lambda x: int(x.replace('℃', '')))
data['日期'] = data['日期'].map(lambda x: int(x.replace('2020年08月', '')[:-1]))
```

可视化

在画图之前，需要创建画板，并对他进行初始化：

```
def initplot():
    plt.figure(figsize=(15, 7))
    plt.grid(True)
    x_major_locator = MultipleLocator(1)
    y_major_locator = MultipleLocator(1)
    # ax为两条坐标轴的实例
    ax = plt.gca()
    # 把x轴的主刻度设置为1的倍数
    ax.xaxis.set_major_locator(x_major_locator)
    #把y轴的主刻度设置为1的倍数
    ax.yaxis.set_major_locator(y_major_locator)
    plt.yticks(np.arange(30, 40))
    plt.xticks(np.arange(1, 24))
    plt.title("单变量线形回归预测天气-杭州08月")
```

初始化面板后，开始画图。在画图结束后在每个点添加数据标签，使数据可视化更加清晰：

```
plt.plot(data['日期'], data['最高气温'], 'k.')
for a, b in zip(data['日期'], data['最高气温']):
    plt.text(a, b, b, ha="center", va="bottom", fontsize=12)
plt.show()
```

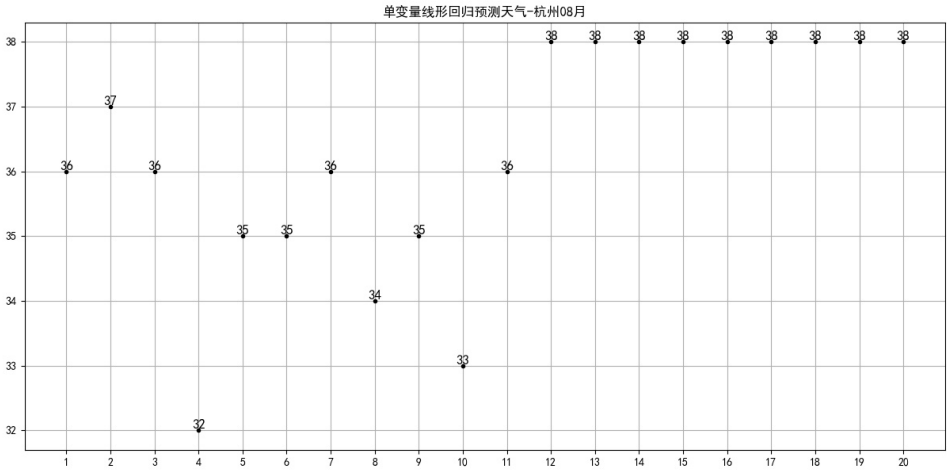

三、单变量线形回归

需要的模块

- *from* sklearn.linear_model *import* LinearRegression

建立模型

定义自变量和因变量

首先将清洗好的日期和最高气温使用numpy模块转换成矩阵 xTrain为训练数据的因变量，yTrain为训练数据的结果值。

```
# 将日期转为矩阵
xTrain = np.array(data['日期'])[:, np.newaxis]
# 将最高气温转换成列向量
yTrain = np.array(data['最高气温'])
```

调用模型创建预测模型

调用LinearRegression()对象预测,得到截距斜率等数据,通过该对象的predict()方法获取预测数据,并转换成矩阵传入plot中得到对象图像.

```
model = LinearRegression()
# 根据训练数据拟合出直线(以得到假设函数)
hypothesis = model.fit(xTrain, yTrain)
# 截距
print("直线截距=", hypothesis.intercept_)
# 斜率
print("直线斜率=", hypothesis.coef_)
print("单变量线性回归预测:2020年8月21日的最高气温：", model.predict([[21]])[0])

# 将预测值在图像中显示出来
for i in [21, 22, 23]:
    plt.text(i,
             model.predict([[i]])[0],
             model.predict([[i]])[0],
             ha="center",
             va="bottom",
             fontsize=10)
# 将从开始到预测的日期转换成矩阵形式
```

```
xNew = np.array([
    1,
    23,
])[:, np.newaxis]
# 传入日期矩阵，获取预测值
yNew = model.predict(xNew)
# 用虚线画出图像
plt.plot(xNew, yNew, 'g--')
```

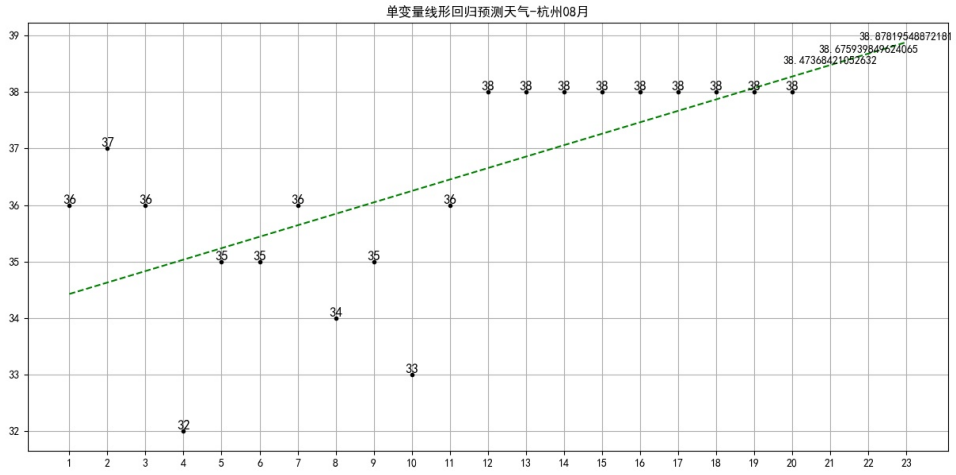

模型评测

评测的方法主要依靠训练组和测试组的残差平方和和R方评价。

训练组的残差平方和：ssResTrain = sum((hpyTrain - yTrain) ** 2) --- model._residues

测试组的残差平方和：ssResTest = sum((hpyTest - yTest) ** 2) --- model.score(xTest, yTest)

R方：Rsquare = 1 - ssResTest / ssTotTest

```
# 引入测试组横坐标，并转换成矩阵
xtest = np.array([3, 6, 9, 12, 15, 18])[:, np.newaxis]
# 引入测试组的纵坐标，转换成矩阵
ytest = np.array([36, 35, 35, 38, 38, 38])
# 测试组的预测值
hpyTest = model.predict(xtest)
# 计算测试组的残差
ssResTest = sum((ytest - hpyTest)** 2)
print(f"训练组的残差为{model._residues}")
print(f"测试组的残差为{ssResTest}")
```

```
单变量线性回归
直线截距= 34.22631578947369
直线斜率= [0.20225564]
训练组的残差为 39.346616541353384
测试组的残差为 5.029034428175677
单变量线性回归预测 :2020年 8月 21日 的最高气温：  38.47368421052632
```

模型评价

对于该模型，其实日期和温度没有很大的关系，座椅该模型的残差会很大，而且预测得到的数据没有具体意义。

四、其他想法

日期和温度几乎没有关联性，在设计模型的时候可以设置权重，按照月份每个月份都可以设置一个基础温度，然后根据天气情况(晴，多云，下雨等)和湿度对温度预测。

基础温度：可以从前几年的数据中的所有月进行平均值处理，然后根据气温上升得到趋势，预测今年每个月的基础温度。

天气情况：天气情况这四个天气可以设置权重值a，并根据天气具体情况x进行哈希处理 {x：a}组成字典，用于表示基础温度变化的影响程度，可正可负。

湿度：湿度和天气情况的道理一样，设置一个权重b，并根据湿度的范围y进行哈希{y：b}，用于表示对基础温度变化的影响程度，可正可负。